LENTE BRASIL

Plano técnico de evolução do observatório público nacional

Versão: 1.0 — 20/10/2026
Repositório analisado: https://github.com/miguelvaztostes/lentebrasil
Referência de código: branch `main`, árvore Git `e49ac2059431eeec760f97843e41b97adad4c388`
Escopo: diagnóstico estático do repositório, arquitetura-alvo, modelo de conectores, portal consultivo nacional, pesquisa, colaboração, segurança, governança e plano de implantação.
Não realizado: execução dos containers, consultas ao banco de produção, testes operacionais dos 165 candidatos do inventário e alterações no GitHub.

> **Decisão central:** evoluir o produto já implementado em vez de recomeçar. Manter a consulta pública sem login, cadastrar primeiro o catálogo nacional completo de fontes candidatas e publicar números somente quando forem efetivamente ingeridos e validados.

1. Visão do produto e fronteiras

O **Lente Brasil** será o portal consultivo nacional de dados públicos. **Lente Ribeirão** será uma visualização territorial dedicada a Ribeirão Preto, usando a mesma infraestrutura e o mesmo catálogo, sem banco ou aplicação duplicada. O produto será independente e não deve sugerir parceria, aprovação ou caráter oficial de qualquer governo, instituto, partido político ou universidade sem autorização explícita.

Entregas fundamentais: (a) descobrir dados oficiais; (b) catalogar fontes e suas condições de acesso; (c) importar dados públicos conforme formato e licença; (d) transformar e validar séries históricas; (e) publicar consultas por município/UF/Brasil e por entidade; (f) comparar territórios em recortes metodologicamente compatíveis; (g) mostrar fonte, datas, revisão e limitações; (h) disponibilizar API e exportações; (i) receber sugestões de novas fontes com moderação.

Três objetos diferentes, três estados diferentes: uma *fonte descoberta* não é necessariamente um *conector implementado*; um conector que executa não significa *dado homologado*; um dado homologado pode não ter cobertura para determinado município, ano ou dimensão. O portal deve mostrar essas distinções em todas as telas.

2. Estado atual comprovado no GitHub

Camada	Arquivo(s) existentes	Diagnóstico
Web	`apps/web/app`, `apps/web/components`, `apps/web/lib/api.ts`	Next.js + TypeScript + Tailwind + Recharts. Home, fontes, indicadores, metodologia, saúde, transparência e educação. Parte dos módulos está em preparação.
API	`apps/api/src/lente_api/api.py`, `main.py`, `schemas.py`	FastAPI `/api/v1`, OpenAPI, listagens, séries, resumo, CSV, saúde e situação das pipelines.
Persistência	`models.py`, `alembic/versions/0001_initial_schema.py`	PostgreSQL: municípios, fontes, datasets, indicadores, observações, revisões, snapshots, execuções e questões de qualidade.
Coleta	`workers/ingestion/ingestion/adapters/*.py`	Contrato `SourceAdapter` com `discover/fetch/parse/validate`; conectores concretos IBGE população, Siconfi RREO e CNES agregado.
Orquestração	`scheduler.py`, `cli.py`	Loop sequencial configurado por variável de ambiente; não é fila distribuída nem agenda por dataset.
Operação	`compose.yaml`, `infra/Caddyfile`, `infra/backup.sh`, `.github/workflows/ci.yml`	Docker Compose, PostgreSQL 16, Caddy opcional, backup/restore e CI com lint/testes/build.
Proveniência	`docs/DATA_DICTIONARY.md`, `docs/SOURCES.md`	Hash SHA-256, snapshot, data de coleta, período, licença, status e método já previstos.

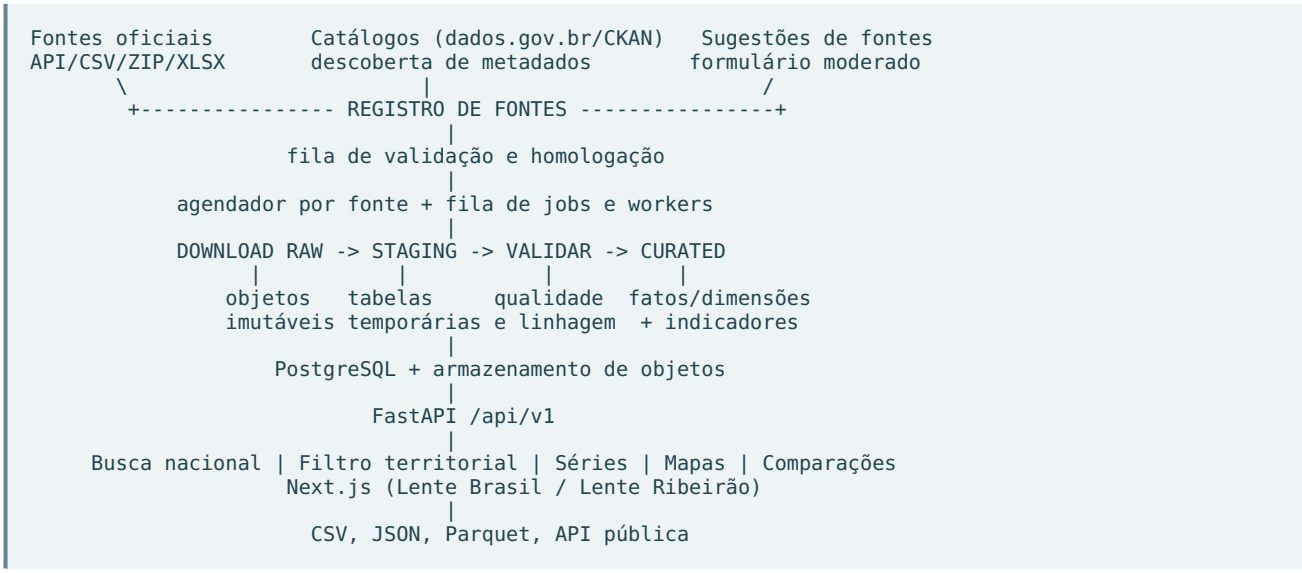
Bloqueios concretos antes de nacionalizar

1. **Município hard-coded.** Os três adaptadores trabalham especificamente com `3543402` (e o CNES também com `354340`); a migração inicial cadastra somente Ribeirão Preto. O resumo da API fixa a cidade em `api.py`.
2. **Consulta de escala insuficiente.** `GET /indicators/{code}/observations` busca no máximo 2.001 registros antes de aplicar filtros de `scope` em Python; a contagem/paginação pode ficar incorreta e perde desempenho em escala nacional. Mover filtros, ordenação e contagem para SQL, adicionar índices e paginação por cursor para grandes séries.
3. **Detalhamento territorial insuficiente.** O registro `Observation` requer `municipality_ibge_code`; para escola, hospital, unidade administrativa, contrato, bairro e indicadores estaduais/nacionais, precisamos de dimensões e fatos próprios, sem colocar todos os dados brutos dentro de `scope_json`.
4. **Ingestão sequencial com ciclo único.** O `scheduler.py` chama todas as fontes a cada intervalo fixo. Implementar políticas individuais por dataset, locks, checkpoint, retry/backoff e execução incremental. Respeitar restrições de requisições da fonte.
5. **Frontend municipal.** Home, cabeçalho, cartões e detalhe de indicador ainda assumem Ribeirão Preto. Adicionar seleção geográfica persistente na URL e visões Brasil, UF, município e entidade.

6. **Cobertura inicial limitada.** O repositório possui somente três integrações automáticas; educação/IDEB permanece em importação supervisionada. Não publicar disponibilidade fictícia do catálogo.
7. **API e dados massivos.** CSV síncrono limitado a 10 mil linhas; para consultas grandes usar jobs de exportação assíncrona, arquivos particionados e URLs temporárias. Evitar N+1 ao resolver fonte/snapshot de cada observação.
8. **Limitações de testes.** Existem testes de parsers, API e integração de repositório, mas não cobertura nacional, concorrência, carga massiva, autorização de contribuintes ou publicação moderada.

Preservar: contrato dos adaptadores, migrations, rastreabilidade de snapshots, semântica zero ≠ ausente, histórico de revisões, padrões de UI, identidade visual, CI e Docker.

3. Arquitetura-alvo



Tecnologia prioritária: reutilizar FastAPI, Next.js e PostgreSQL. Adicionar armazenamento de objetos compatível com S3 para arquivos que possam ser legalmente retidos, Redis + fila de jobs (ex.: RQ, Celery ou Dramatiq, decisão por benchmark) e PostgreSQL com índices/partições/materializações. Usar Parquet + DuckDB/Polars para tratamento de grandes arquivos. Não adotar Kubernetes, Kafka, data warehouse externo ou Elasticsearch antes de haver necessidade medida.

Princípio de operação: o usuário consulta o dado já processado no Lente; o frontend não dispara a coleta nas APIs governamentais a cada acesso. Último dado válido permanece disponível caso a fonte esteja temporariamente fora do ar, com alerta de desatualização.

4. Modelo de dados proposto

4.1 Catálogo e governança

- `data_providers`: nome oficial, CNPJ quando aplicável, esfera, site, contato público, classificação de origem.
- `data_sources`: provedor, fonte oficial, URL de origem, documentação, licença, condições de reutilização, autenticação, política de atualização, situação de verificação.

- `source_resources`: **cada arquivo ou endpoint individual** com tipo (`api`, `csv`, `zip`, `xlsx`, `parquet`, `ckan`, `portal`, `manual`), URL direta, paginação, formato, schema, escopo geográfico, parâmetros, limite, versão e hash.
- `datasets`: unidade semântica estável; pode reunir vários recursos anuais do mesmo conjunto.
- `dataset_coverage`: geografia, nível de agregação, primeiro/último período, indicadores e dimensões disponíveis.
- `indicator_definitions`: fórmulas, unidade, unidade-base, polaridade se aplicável, periodicidade, definição, denominador e compatibilidade temporal.
- `connector_definitions`, `connector_runs`, `ingestion_artifacts`, `validation_rules`, `quality_issues`, `publication_releases`.
- `source_submissions`, `submission_reviews`, `organizations`, `users`, `audit_events`: cadastrar futuramente, inicialmente invisíveis ao público geral exceto formulário de sugestão.

4.2 Dimensões territoriais e institucionais

- `geo_units`: Brasil, UF, município, região, distrito e outras divisões oficiais quando disponíveis; código IBGE 7 dígitos para município, geocódigos e validade histórica.
- `geo_code_mappings`: conversão dos códigos das fontes (ex.: CNES seis dígitos, Siconfi, códigos próprios) para a chave canônica, com validade temporal e origem do mapeamento.
- `schools`: código INEP, município, rede, esfera e período válido; não publicar informações pessoais indevidas.
- `health_establishments`: código CNES, município, tipo e atributos não sensíveis autorizados.
- `public_agencies`, `procurements`, `contracts`, `suppliers` (campos pessoais e sensíveis sob revisão de publicação), `budget_accounts`, `programs`, `elections`, `environmental_stations`.

4.3 Fatos, séries e grãos

Manter a tabela legada `observations` e criar um modelo genérico `indicator_observations` (geo_nível, geo_id, indicador, período, versão e dimensões normalizadas) para agregados. Tabelas volumosas/transacionais — contratos, empenhos, matrículas detalhadas, estabelecimentos e ocorrências — devem ter fatos separados e materializações por município/ano/tema.

Não colocar tudo em JSONB indiscriminadamente. JSONB serve para metadados/dimensões flexíveis, mas filtros recorrentes e relacionamentos têm colunas/indexação próprias. Definir chaves compostas, índices cobrindo `(indicator_id, geo_id, period_end)`, deduplicação por fonte/período/grão e partições quando justificadas por volume.

Criar *views de compatibilidade* para manter `/api/v1/indicators/{code}/observations` funcionando durante a migração. Cada linha publicada deve apontar para `snapshot_id`, execução, versão, licença e transformação aplicada.

5. Inventário de conectores e estratégia de ingestão

Entrada: `/mnt/data/Lente_Inventario_Nacional_Fontes_2026.json` e catálogo XLSX preparados em 20/10/2026. O inventário tem **165 registros candidatos**, distribuídos em **16 áreas** e **95 indicadores propostos**; **61 registros estão marcados P0** no JSON atual. *Esses valores são contagens do inventário, não conectores existentes ou APIs já testadas.* Algumas fontes se repetem em diferentes indicadores e algumas entradas têm apenas link de portal.

Ordem técnica	Fonte(s) / módulo	Forma predominante	Estratégia de primeiro conector
0	IBGE Localidades e malhas	API JSON / GeoJSON	Popular todas as unidades territoriais e códigos de referência; atualizar sob controle.
0	IBGE SIDRA / Agregados	API JSON	Parametrizar indicadores e regiões; consultas em lote e limites da API; preservar unidade/ano.
0	CNES	ZIP/CSV ou API oficial	Baixar recurso nacional **uma vez por versão**; processar por município; materializar agregados; evitar download por cidade.
0	Siconfi: RREO, RGF, DCA	API REST	Parametrizar ente, ano, anexo, período; cache/ checkpoint; lotes obedecendo rate limits; avaliar exportações oficiais em bloco.
1	Inep Censo Escolar, Ideb, Saeb	ZIP/CSV/XLSX	Processar arquivos anuais, códigos de escola/rede e marcadores de ausência; homologação por série.
1	TCE-SP receitas/despesas	arquivos ZIP/CSV	Carga por exercício e município no ETL; conciliar classificações com Siconfi, sem somar duplicado.
1	PNCP	API REST	Extrair contratações incrementais por publicação/atualização, órgão e município, paginando.
1	Ministério da Saúde (DEMAS), SIM, SINASC, SIH	API e arquivos DATASUS	Separar o que é agregado/ publicável de microdados passíveis de reidentificação.
1	FNDE, MDS e SINISA	ZIP/CSV/portais	Validar cada recurso/ano e normalizar programa, geografia e ano.
2	Novo CAGED, RAIS, PIB municípios, Comex	arquivos e APIs IBGE	Cargas grandes por ano/ mês, indicadores econômicos comparáveis; considerar sigilo estatístico.
2	SSP-SP, TSE, ANEEL, Senatran, INPE	CSV/API/GeoJSON	Conectores especializados por tema e validação geográfica.

Ordem técnica	Fonte(s) / módulo	Forma predominante	Estratégia de primeiro conector
2	Dados estaduais e municipais	CKAN/API/arquivo/portal	Descoberta por catálogo e curadoria; conector por plataforma ou ente.

Conector padronizado: `discover -> fetch -> stage -> parse -> validate -> reconcile -> publish`. Cada conector recebe parâmetros como `geographies`, `period_range`, `resource_version`, `updated_since`, `dry_run`. Deve implementar idempotência, checkpoint, políticas de atualização por fonte, limites, retries com backoff, `ETag`/`Last-Modified` quando presentes, log e métricas.

Regra: diferenciar o link da página do conjunto, o link de documentação, o endpoint de API, e o link efetivo de download. Nunca assumir que um URL de portal entrega CSV. Critério de `validated`: recurso respondendo, esquema lido, amostra cruzada, licença revisada, período e geografia conferidos.

Capacidade: não executar uma requisição do Siconfi por município *sincronamente na visita do usuário*. Analisar lotes/arquivos antes de multiplicar milhares de entidades por anos e bimestres. Usar fila com orçamento por provedor, prioridades e atualização incremental. Não presumir que um endpoint aceite consulta de todos os municípios sem consultar sua documentação.

6. Área pública de consulta — escopo do primeiro lançamento

Navegação proposta

- `/` — Lente Brasil: pesquisa principal, atalhos por tema, fontes integradas e situação de cobertura.
- `/brasil` — panorama nacional somente com indicadores compatíveis.
- `/estados/[uf]` — visão estadual.
- `/municipios/[ibgeCode]` — visão municipal; `/municipios/3543402` reproduz o Lente Ribeirão.
- `/municipios/[ibgeCode]/[setor]` — setor no município.
- `/indicadores/[codigo]` — série, metodologia, fonte, cobertura, comparações e CSV.
- `/fontes`, `/fontes/[id]` — catálogo consultável com status e acesso ao recurso original.
- `/comparar` — municípios/UFs, mesmo indicador/período/unidade.
- `/dados-abertos` — documentação de API e arquivos de exportação.
- `/contribuir/fonte` — sugerir fonte ou reportar problema; inicialmente revisão manual.
- `/pesquisa` — entrada pública para ferramentas de pesquisa, sem obrigação de cadastro.

Exemplo de pesquisa: “Ribeirão Preto / educação / IDEB / 2025” deve mostrar cidade, datasets relevantes e, se a importação estiver homologada, valores e gráficos. Se não estiver, mostrar `Fonte identificada — ainda não integrada`, e link oficial. Nunca gerar número substituto.

Facetas: termo livre; região; município/UF; setor; origem; granularidade; período; tipo de recurso (API, CSV etc.); licença; atualizado em; qualidade; disponibilidade. O filtro territorial deve persistir na URL e em links de compartilhamento, evitando estado implícito do navegador.

Ranking e comparações: só habilitar quando mesmo conceito, denominador, periodicidade e geografia forem comparáveis. Exibir o período da fonte e não tratar data de coleta como referência estatística.

Endpoints propostos — não existentes hoje

```
GET /api/v1/geo/municipios?q=Ribeirao&uf=SP&limit=20
GET /api/v1/search?q=ideb&geo_id=3543402&kind=indicator,dataset
GET /api/v1/municipios/3543402/summary
GET /api/v1/municipios/3543402/indicators?domain=educacao&period=2025
GET /api/v1/indicators/ideb/observations?geo_type=municipio&geo_id=3543402&period=2025
GET /api/v1/compare?indicator=population_estimated&geo_ids=3543402,3509502&period=2025
GET /api/v1/sources?domain=saude&integration_status=active
GET /api/v1/datasets/{id}/coverage
GET /api/v1/exports/{jobId}/status
POST /api/v1/source-submissions
```

Usar SQL parametrizado e índices, contrato OpenAPI, filtros no servidor, paginação por cursor nos grandes conjuntos, rate limit/quotas e cache com invalidação por `publication_release`. Evitar exportações gigantes consumindo memória da API.

Lançamento: duas camadas públicas

1. **Catálogo completo navegável:** todas as 165 entradas como candidatas, agrupadas e deduplicadas por fonte/recurso; etiquetas `descoberta`, `em validação`, `integrada`, `desatualizada`, `restrita` e `indisponível`.
2. **Observatório de dados reais:** somente indicadores cujo conector e tratamento tenham sido homologados. Começar pelas três fontes existentes generalizadas, depois adicionar lotes de educação, finanças/PNCP e demais setores. Indicar cobertura por município e ano — um catálogo completo não equivale a cobertura integral de dados.

7. Portal de pesquisa e cadastro de pesquisadores

Decisão recomendada: não exigir conta para consultar, filtrar, comparar ou baixar dados públicos permitidos. Criar uma seção **Pesquisa** inicialmente aberta, com construtor avançado de consultas, dicionário, metodologia, exportação e link permanente com parâmetros. Contas entram *apenas* quando houver valor funcional claro: salvar consultas, coleções, cadernos públicos, alertas, gestão de projetos, chaves de API com quotas ou submissão identificada.

Referências internacionais: o `data.gov.uk` usa catálogo pesquisável e API CKAN e referencia recursos mantidos pelas organizações publicadoras; o Zenodo combina depósitos, registros/versionamento e comunidades com curadoria e permissões. Adotar os padrões de descoberta e moderação, **não** a complexidade completa dessas plataformas na primeira fase.

Modelo de permissões futuro: `anonymous_reader`, `registered_researcher`, `contributor`, `verified_organization_publisher`, `curator`, `data_steward`, `administrator`. Dados públicos continuam acessíveis anonimamente. Perfis privados de pesquisa não conferem privilégio automático de publicar na base oficial.

8. Novas fontes — descoberta, sugestão e contribuição

Não abrir escrita direta nos dados oficiais. Criar um **workflow de proposição e revisão** separado da pipeline de publicação:

```
CADASTRAR SUGESTÃO
URL oficial / descrição / órgão / localização / licença / contato público
          |
RECEBIDA -> TRIAGEM (duplicatas e legitimidade)
          |
VERIFICAÇÃO DE FONTE, FORMATO E DIREITOS DE REUSO
          |
TESTE EM QUARENTENA (sem afetar o dado publicado)
          |
VALIDAÇÃO HUMANA + TESTES DE QUALIDADE + VERSÃO
          |
APROVADA -> CONECTOR AGENDADO -> DATASET PUBLICADO
          |
REVALIDAÇÃO CONTÍNUA -> ALERTA / SUSPENSÃO / REVISÃO
```

Três caminhos de entrada: (1) descoberta automatizada de metadados em catálogos oficiais como CKAN e dados.gov.br; (2) formulário público `Sugerir base` para cidadãos/pesquisadores; (3) organização verificada que indica endpoint ou envia arquivos em área autenticada — **apenas após implantação da governança e controles**. O suporte serve para exceções, não como mecanismo principal de registro.

Status separados: `suggested`, `discovered`, `under_review`, `approved_source`, `connector_in_development`, `active`, `degraded`, `deprecated`, `rejected`. A fonte pode estar catalogada sem jamais ser conectada. Notificar proponentes sobre decisão e justificativa quando houver contato autorizado.

Segurança no recebimento: URLs são metadados até aprovação. Não realizar chamadas de rede automáticas a URLs fornecidas por usuários; após revisão aplicar allowlist de domínios oficiais, bloqueio de IP privado/loopback/metadata, resolução DNS e redirects verificados, proteção SSRF, timeout, limite de tamanho, rate limit, antivírus, validação MIME+conteúdo, proteção contra ZIP bombs, arquivos em quarentena, varredura de dados pessoais e revisão de licença. Credenciais de prefeituras jamais aparecem no frontend/logs ou repositório.

Autenticidade: domínios oficiais, metadados de órgão, origem e contato institucional; publicação identificada como **“base oficial de origem”** versus **“base enviada por terceiro e validada pelo Lente”**. Nunca afirmar endosso ou publicação oficial pelo Lente sem processo formal de verificação.

Monitoramento: agendamento de descoberta, verificação de status HTTP e mudanças de `ETag`/`Last-Modified`, divergência de schema, atrasos de atualização, sumiço de recurso, campos novos e mudanças de licença. Mudanças não são autopublicadas: reprocessamento com testes e política de aprovação por risco.

9. Segurança, privacidade, qualidade e governança

- **Dado público não significa publicação irrestrita de dado pessoal.** Base legal, finalidade, minimização, agregação, risco de reidentificação e política de retenção devem ser avaliados antes da reprodução, especialmente em saúde, educação, benefícios e microdados.
- Encriptar transporte (TLS), segredos em gerenciador/variáveis protegidas, contas técnicas de menor privilégio, rotação, RBAC no backoffice, MFA para curadores, auditoria de ações, backups cifrados fora da VM e restauração testada.
- Registrar `raw_sha256`, fonte, `source_published_at`, `ingested_at`, `reference_period`, versão do parser, licença, transformações, regra de cálculo, código geográfico e `release_id`.
- Validações mínimas: contrato/schema, linhas vazias, tipos, duplicidades, consistência temporal, valores extremos, limites de linhas, totais conciliáveis, estabilidade de municípios, cardinalidade, não divulgação indevida de dados identificáveis.
- Números contraditórios de duas fontes devem aparecer com nome de fonte e definição diferentes; não sobrescrever arbitrariamente. Não misturar empenhado, liquidado e pago; não usar valor acumulado do bimestre como mensal.

- Documentar correções e revisões com data; permitir auditoria e download da definição do indicador.
- Política de licença e citação: conferir fonte por recurso, não assumir que todas as bases federais compartilham as mesmas condições.

10. Observabilidade e operação

Métricas por fonte: duração, bytes, registros recebidos/válidos/rejeitados, data mais recente, defasagem, `schema_drift`, falhas HTTP, retries, custo de processamento e última publicação. **API:** latência p50/p95, taxa 5xx, cache hit, queries lentas e downloads. **Infra:** PostgreSQL CPU, conexões, tamanho, volume de objetos, backlog e duração dos jobs. **Alertas:** pipeline crítica atrasada, qualidade fora dos limites, falha de backup, alteração de schema e certificado expirando.

SLIs sugeridos (metas a definir após linha de base): disponibilidade de consulta, percentual de fontes críticas em dia, integridade de proveniência, sucesso de ingestão, latência da pesquisa e tempo de publicação após release oficial. Um indicador antigo por natureza não deve ser tratado como falha apenas pela ausência de atualização mensal.

11. Roadmap de implementação — entregáveis e aceite

Etapa 0 — Base de segurança e compatibilidade

Objetivo: expandir sem romper o MVP.

- Criar branch de evolução; congelar contratos atuais com testes de regressão.
- Registrar versão do catálogo e migrar fontes candidatas com deduplicação.
- Implementar migrations aditivas de geografia/recurso/status; preservar dados legados. **Aceite:** CI passando, migrações reversíveis/backup, endpoints antigos operando.

Etapa 1 — Nacionalizar as três integrações existentes

- Popular municípios/UFs pela API IBGE, com validação e atualização controlada.
- Parametrizar IBGE e Siconfi para múltiplos municípios; adaptar CNES para processar o arquivo nacional por lote.
- Agendar backfills e cargas incrementais; separar `job` por fonte/recurso/ano/partição.
- Corrigir paginação, SQL de filtros, índices e resposta do dashboard por município. **Aceite:** ao menos três municípios escolhidos por teste, incluindo Ribeirão Preto, com valores independentes e atribuídos corretamente; nenhum município no código de ingestão; `/municipios/3543402` preserva resultados existentes.

Etapa 2 — Catálogo nacional e busca pública

- Importar as 165 entradas candidatas mantendo proveniência e estado `não homologado`.
- Publicar `/fontes`, `/search`, `/municipios/[id]`, `/brasil`, `/estados/[uf]`, filtros por setor, período e formato.
- Exibir ausência/cobertura com clareza e links oficiais. **Aceite:** busca por qualquer município cadastrado e fontes por setor, sem falsos números; fonte disponível para descoberta mesmo antes da ingestão.

Etapa 3 — Expansão dos módulos de maior valor

- Adicionar conectores baseados no catálogo: INEP Censo/Ideb; TCE-SP arquivos; PNCP; Ministério da Saúde; SINISA; MTE/RAIS/CAGED segundo validação dos recursos.
- Introduzir tabelas de escolas/estabelecimentos/contratos e agregações.
- Exportações CSV/Parquet com fila de tarefas. **Aceite:** pelo menos um conjunto homologado em cada tema prioritário; histórico e município verificados; documentação de regras por dataset e reconciliação de amostras com fonte oficial.

Etapa 4 — Comparador e pesquisa avançada

- Comparação geográfica com contratos de comparabilidade; mapa nacional; pesquisa facetada.
- API de séries de múltiplas geografias; visualização de cobertura e qualidade. **Aceite:** comparação de município com município somente quando metodologia, ano e denominador forem compatíveis; links compartilháveis reproduzem filtros.

Etapa 5 — Contribuição, curadoria e perfis opcionais

- Formulário público de indicação de fontes; backoffice moderado; monitor automático de catálogos.
- Organizações verificadas com fluxos de submissão em quarentena; pesquisadores cadastrados apenas para recursos de trabalho pessoal. **Aceite:** URL maliciosa/arquivo inadequado não alcança ingestão; nenhuma fonte proposta é publicada sem aprovação; auditoria e fluxo de rejeição funcionando.

12. Primeiras tarefas para o Codex (ordem estrita)

1. `NAT-001` Inventário do código e testes base: registrar APIs legadas, fixtures e plano de migração.
2. `NAT-002` Migração territorial: `geo_units`, `geo_code_mappings` e seed oficial IBGE.
3. `NAT-003` Refatorar `IbgePopulationAdapter`: parametrização e consulta multi-geografia com lote e verificações.
4. `NAT-004` Refatorar `CnesAdapter`: agregar todos os municípios do arquivo nacional em uma carga, guardando compatibilidade.
5. `NAT-005` Refatorar `SiconfiRreoAdapter`: job por ente/ano e rate-limit persistente + checkpoint.
6. `NAT-006` Corrigir `/observations`: filtro de dimensões em SQL, total correto, paginação e índices.
7. `NAT-007` Expor `/municipios/{code}/summary` com payload geográfico selecionável.
8. `NAT-008` Criar UI de busca/seleção geográfica, rotas nacionais e foco inicial em Ribeirão Preto.
9. `NAT-009` Importar catálogo de 165 candidatos como metadados, sem declarar ingestão concluída; resolver duplicatas de recursos.
10. `NAT-010` Expor busca de fontes/indicadores com facetas, qualidade e cobertura.
11. `NAT-011` Implementar InEp Censo Escolar e IDEB após validação de schema e direitos.
12. `NAT-012` Criar test suite multicípio, testes de regressão, performance e verificação de proveniência.

Critério de término da primeira entrega nacional: menu Brasil/UF/município; Ribeirão funcionando; ao menos três conectores existentes adaptados para cobertura nacional ou reprocessamento controlado multicípio; catálogo de fontes pesquisável; status honesto de dados reais; API documentada; backup/restore; CI e testes de regressão. Isso não implica que todas as fontes candidatas estejam integradas na mesma entrega.

13. Regras de aceite por dataset

Para cada dataset efetivamente publicado, exigir: (1) URL e licença conferidas; (2) recurso e formato reconhecidos; (3) versão arquivada ou hash+URL quando retenção do bruto não permitida; (4) schema validado; (5) municípios/entidades reconciliados; (6) ano/periodicidade/unidade explícitos; (7) ausência e zero distintos; (8) duplicidade controlada; (9) amostra comparada ao portal oficial; (10) cobertura publicada; (11) atualização/alerta configurado; (12) API + CSV testados; (13) tratamento LGPD documentado; (14) rollback/retirada de publicação possíveis.

14. Referências e links

Código auditado:

- Repositório: https://github.com/miguelvaztostes/lentebrasil
- API: https://github.com/miguelvaztostes/lentebrasil/blob/main/apps/api/src/lente_api/api.py
- Modelos: https://github.com/miguelvaztostes/lentebrasil/blob/main/apps/api/src/lente_api/models.py
- Coletor base: https://github.com/miguelvaztostes/lentebrasil/blob/main/workers/ingestion/ingestion/adapters/base.py
- IBGE: https://github.com/miguelvaztostes/lentebrasil/blob/main/workers/ingestion/ingestion/adapters/ibge.py
- Siconfi: https://github.com/miguelvaztostes/lentebrasil/blob/main/workers/ingestion/ingestion/adapters/siconfi.py
- CNES: https://github.com/miguelvaztostes/lentebrasil/blob/main/workers/ingestion/ingestion/adapters/cnes.py
- Documentação legada: https://github.com/miguelvaztostes/lentebrasil/tree/main/docs

Modelos internacionais e segurança:

- Diretório CKAN e API de descoberta do Reino Unido: https://guidance.data.gov.uk/get_data/api_documentation/
- Publicação descentralizada no Reino Unido: https://guidance.data.gov.uk/publish_and_manage_data/
- CKAN Action API: https://docs.ckan.org/en/latest/api/
- Comunidades com curadoria no Zenodo: https://help.zenodo.org/docs/communities/
- API para depósitos de pesquisa do Zenodo: https://developers.zenodo.org/
- OWASP SSRF Prevention: https://cheatsheetseries.owasp.org/cheatsheets/Server_Side_Request_Forgery_Prevention_Cheat_Sheet.html

Fonte do inventário nacional: arquivos previamente preparados `Lente_Inventario_Nacional_APIs_Downloads_2026.xlsx` e `Lente_Inventario_Nacional_Fontes_2026.json` (165 registros candidatos). A enumeração e homologação de conectores ocorrerão em etapas posteriores.

Conclusão executiva: não há necessidade de mudar de stack nem construir outro projeto. Primeiro: nacionalizar a arquitetura e tornar o catálogo inteiro pesquisável; em paralelo, tornar reais e multicípio os conectores já existentes. Depois: adicionar conectores especializados por conjunto de dados, com controle de qualidade e publicação. Cadastros de pesquisadores, prefeituras e novas bases devem ser planejados desde agora, mas sua ativação acontece em etapa posterior, sem comprometer a consulta pública livre e independente.